

Progettazione logica

Prof. Stefano Rizzi

Modelli logici per il Data Mart

- Mentre la modellazione concettuale è indipendente dal modello logico prescelto per l'implementazione, evidentemente lo stesso non si può dire per i temi legati alla modellazione logica.
- La struttura multidimensionale dei dati può essere rappresentata utilizzando due distinti modelli logici:
 - ✓ **MOLAP** (*Multidimensional On-Line Analytical Processing*) memorizzano i dati utilizzando strutture intrinsecamente multidimensionali (es. vettori multidimensionali).
 - ✓ **ROLAP** (*Relational On-Line Analytical Processing*) utilizza il ben noto modello relazionale per la rappresentazione dei dati multidimensionali.




Sistemi MOLAP

- L'utilizzo di soluzioni MOLAP:

- ✓ Rappresenta una soluzione naturale e può fornire ottime prestazioni poiché le operazioni non devono essere "simulate" mediante complesse istruzioni SQL.
- ✓ Pone il problema della sparsità: in media solo il 20% delle celle dei cubi contiene effettivamente informazioni, mentre le restanti celle corrispondono a fatti non accaduti.
- ✓ È frenato dalla mancanza di strutture dati standard: i diversi produttori di software utilizzano strutture proprietarie che li rendono difficilmente sostituibili e accessibili mediante strumenti di terze parti.
- ✓ Progettisti e sistemisti sono riluttanti a rinunciare alla loro ormai ventennale esperienza sui sistemi relazionali.

3




Sistemi MOLAP e sparsità

- Le tecniche di gestione della sparsità sono basate sui seguenti principi:

- ✓ Suddivisione delle dimensioni: consiste nel partizionare un cubo n -dimensionale in più sottocubi n -dimensionali (*chunk*). I singoli chunk potranno essere caricati più agevolmente in memoria e potranno essere gestiti in modo differente a seconda che siano *densi* (la maggior parte delle celle contiene informazioni) oppure *sparsi* (la maggior parte delle celle non contiene informazioni).
- ✓ Compressione dei chunk: i chunk sparsi vengono rappresentati in forma compressa al fine di evitare lo spreco di spazio dovuto alla rappresentazione di celle che non contengono informazioni.

4

Sistemi MOLAP e sparsità



Una struttura dati comunemente usata per la compressione dei chunk sparsi prevede un indice che riporti il solo offset delle celle che effettivamente contengono informazioni.


5

ROLAP: lo schema a stella

- La modellazione multidimensionale su sistemi relazionali è basata sul cosiddetto *schema a stella* (*star schema*) e sulle sue varianti.
- Uno schema a stella è composto da:
 - ✓ Un insieme di relazioni DT_1, \dots, DT_n , chiamate *dimension table*, ciascuna corrispondente a una dimensione. Ogni DT_i è caratterizzata da una chiave primaria (tipicamente surrogata) d_i e da un insieme di attributi che descrivono le dimensioni di analisi a diversi livelli di aggregazione.
 - ✓ Una relazione FT , chiamata *fact table*, che importa le chiavi di tutte le dimension table. La chiave primaria di FT è data dall'insieme delle chiavi esterne dalle dimension table, d_1, \dots, d_n ; FT contiene inoltre un attributo per ogni misura.

6

Lo schema a stella



Settimane

ID_Settimane
Settimana
Mese

Prodotti

ID_Prodotti
Prodotto
Tipo
Categoria
Fornitore

Negozi

ID_Negozi
Negozio
Città
Stato
Rappresentante

7

Lo schema a stella

ID_Negozi	Negozio	Città	Stato	Rappresentante
1	N1	RM	I	R1
2	N2	RM	I	R1
3	N3	MI	I	R2
4	N4	MI	I	R2

Dimension Table

ID_Negozi	ID_Sett	ID_Prodotti	Quantità	Guadagno
1	1	1	100	100
1	2	1	150	150
3	3	4	350	350
4	4	4	200	200

Fact Table

ID_Sett.	Settimana	Mese
1	Gen1	Gen.
2	Gen2	Gen.
3	Feb1	Feb.
4	Feb2	Feb.

Dimension Table

ID_Prodotti	Prodotto	Tipo	Categoria	Fornitore
1	P1	A	X	F1
2	P2	A	X	F1
3	P3	B	X	F2
4	P4	B	X	F2


8

Lo schema a stella: considerazioni

- Le Dimension Table sono completamente denormalizzate (es. Prodotto → Tipo)
 - ↳ È sufficiente un join per recuperare tutti i dati relativi a una dimensione
 - ↳ La denormalizzazione introduce una forte ridondanza nei dati
- La Fact Table contiene tuple relative a diversi livelli di aggregazione
 - ↳ L'elevata dimensione incide sui tempi di accesso ai dati
- Non si hanno problemi di sparsità in quanto vengono memorizzate soltanto le tuple corrispondenti a punti dello spazio multi-dimensionale per cui esistono eventi

9

Interrogazioni OLAP su schemi a stella



VENDITE(Negozi.Città, Settimane, Prodotti.Tipo;
Prodotto.Categoria='Alimentari').Quantità

```
select      Città, Settimana, Tipo, sum(Quantità)
from        Settimane, Negoci, Prodotti, Vendite
where       Settimane.ID_Settimane=Vendite.ID_Settimane and
           Negoci.ID_Negozi =Vendite.ID_Negozi and
           Prodotti.ID_Prodotti =Vendite.ID_Prodotti and
           Prodotti.Categoria = 'Alimentari'
group by    Città, Settimana, Tipo;
```


10

Lo snowflake schema

- Lo schema a fiocco di neve (*snowflake schema*) riduce la denormalizzazione delle dimension table DT_i degli schemi a stella eliminando alcune delle dipendenze transitive che le caratterizzano.
- Le dimension table $DT_{i,j}$ di questo schema sono caratterizzate da:
 - ✓ una chiave primaria (tipicamente surrogata) $d_{i,j}$
 - ✓ il sottoinsieme degli attributi di DT_i che dipendono funzionalmente da $d_{i,j}$.
 - ✓ zero o più chiavi esterne a importate da altre $DT_{i,k}$ necessarie a garantire la ricostruibilità del contenuto informativo di DT_i .
- Denominiamo **primarie** le dimension table le cui chiavi sono importate nella fact table, **secondarie** le rimanenti.


11

Lo snowflake schema



12

Lo snowflake schema



13


Lo snowflake schema: considerazioni

- Lo spazio richiesto per la memorizzazione dei dati si riduce grazie alla normalizzazione
- È necessario inserire nuove chiavi surrogate che permettano di determinare le corrispondenze tra dimension table primarie e secondarie
- L'esecuzione di interrogazioni che coinvolgono solo gli attributi contenuti nella fact table e nelle dimension table primarie è avvantaggiata
- Il tempo di esecuzione delle interrogazioni che coinvolgono attributi delle dimension table secondarie aumenta
- Lo snowflake schema è particolarmente utile in presenza di dati aggregati

14


Normalizzazione con lo snowflake schema

- Le specifiche caratteristiche degli schemi a stella richiedono particolare attenzione affinché nella nuova relazione sia spostato il corretto insieme di attributi
- La presenza di più dipendenze funzionali transitive in cascata fa sì che, affinché la decomposizione sia efficace, tutti gli attributi che dipendono (transitivamente e non) dall'attributo che ha determinato lo snowflaking siano posti nella nuova relazione



15

Interrogazioni OLAP su schemi snowflake



16

Le viste


- L'analisi dei dati al massimo livello di dettaglio è spesso troppo complessa e non interessante per gli utenti che richiedono dati di sintesi
 - L'aggregazione rappresenta il principale strumento per ottenere informazioni di sintesi
 - L'elevato costo computazionale connesso con l'aggregazione induce a precalcolare i dati di sintesi maggiormente utilizzati

Con il termine *vista* si denotano le fact table contenenti dati aggregati

17

Le viste

- Le viste possono essere identificate in base al livello (*pattern*) di aggregazione che le caratterizza




- **Viste primarie:** corrispondono al pattern di aggregazione primario (non aggregato)
 - **Viste secondarie:** corrispondono ai pattern di aggregazione secondari (aggregati)

Una interrogazione che richieda i dati aggregati per tipo prodotto, data di vendita e città del negozio risulterà meno costosa se eseguita sulla vista v2 (piuttosto che su v1) poiché insisterà su una fact table con un numero ridotto di tuple e non richiederà ulteriori operazioni di aggregazione.

18

Risolvibilità delle interrogazioni

- Una vista v sul pattern p non serve solo per le interrogazioni con pattern di aggregazione p ma anche per tutte quelle che richiedono i dati a pattern p' più aggregati di p ($p \leq p'$)



19

Schemi relazionali e viste


- La soluzione più semplice consiste nell'utilizzare lo schema a stella memorizzando tutti i dati in una sola fact table
 - ✓ La dimensione dell'unica fact table cresce considerevolmente a discapito delle prestazioni
 - ✓ Le dimension table contengono tuple relative a diversi livelli di aggregazione. Il valore NULL viene utilizzato per identificare l'origine delle tuple.

I record delle dimension table corrispondenti a dati aggregati presenteranno dei valori NULL in tutti i campi il cui livello di aggregazione è più fine di quello su cui si sta operando.

20

Schemi relazionali e viste


Sono relative al pattern:
{Negozi, Settimane, **Prodotti**}



21

Schemi relazionali e viste


Sono relative al pattern:
{Negozi, Settimane, **Tipo**}



22

Schemi relazionali e viste


È relativa al pattern:
{Negozi, Settimane, Fornitore}



23

Schemi relazionali e viste


- Adottando lo snowflake schema è possibile memorizzare in fact table separate dati appartenenti a diversi pattern di aggregazione
 - ✓ Lo snowflaking deve essere applicato in corrispondenza dei livelli di aggregazione a cui sono presenti viste



24

Schemi relazionali e viste


- Una soluzione intermedia rispetto alle due presentate prevede di memorizzare in fact table separate dati relativi a pattern di aggregazione diversi senza però ricorrere alla normalizzazione delle dimension table (*constellation schema*).
 - ✓ L'accesso alle fact table è ottimizzato, quello alle dimension table no.
 - ✓ La dimensione delle fact table è di molto superiore a quella delle dimension table e conseguentemente la loro ottimizzazione gioca un ruolo fondamentale.



25

Schemi relazionali e viste

- Il massimo livello delle prestazioni si ottiene memorizzando in fact table separate dati a diversi livelli di aggregazione e replicando completamente anche le dimension table



26


Aggregate navigator

- La presenza di più fact table contenenti i dati necessari a risolvere una data interrogazione pone il problema di determinare la vista che determinerà il minimo costo di esecuzione.
- Questo ruolo è svolto dagli *aggregate navigator*, ossia i moduli preposti a riformulare le interrogazioni OLAP sulla “migliore” vista a disposizione.
- Gli aggregate navigator dei sistemi commerciali gestiscono attualmente solo gli operatori distributivi riducendo così l’utilità delle misure di supporto.

27

Progettazione logica

- Include l’insieme dei passi che, a partire dallo schema concettuale, permettono di determinare lo schema logico del data mart



- È basata su principi diversi e spesso in contrasto con quelli utilizzati nei sistemi operazionali
 - ✓ Ridondanza dei dati
 - ✓ Denormalizzazione delle relazioni

28

Progettazione logica

- Le principali operazioni da svolgere durante la progettazione logica sono:
 1. Scelta dello schema logico da utilizzare (es. star/snowflake schema)
 2. Traduzione degli schemi concettuali
 3. Scelta delle viste da materializzare
 4. Applicazione di altre forme di ottimizzazione (es. frammentazione verticale/orizzontale)

29

Star VS Snowflake


- Esistono pareri contrastanti sull'utilità dello snowflaking:
 - ✓ Contrastà con la filosofia del data warehousing
 - ✓ Rappresenta un inutile “abbellimento” dello schema
- Può essere utile
 - ✓ Quando il rapporto tra le cardinalità della dimension table primaria e secondaria è elevato, poiché determina un forte risparmio di spazio

30

Star VS Snowflake

- Può essere utile

✓ Quando una porzione di una gerarchia è comune a più dimensioni




La dimension table secondaria è riutilizzata per più gerarchie

31

Star VS Snowflake

- Può essere utile

✓ In presenza di viste aggregate



La dimension table secondaria della vista primaria coincide con la dimension table primaria della vista secondaria

32



Dagli schemi di fatto agli schemi a stella

- La regola di base per la traduzione di uno schema di fatto in schema a stella prevede di:

Creare una fact table contenente tutte le misure e gli attributi descrittivi direttamente collegati con il fatto e, per ogni gerarchia, creare una dimension table che ne contiene tutti gli attributi.

- In aggiunta a questa semplice regola, la corretta traduzione di uno schema di fatto richiede una trattazione approfondita dei costrutti avanzati del DFM.

33




Attributi descrittivi

- Contiene informazioni non utilizzabili per effettuare aggregazioni ma che si ritiene comunque utile mantenere.
 - ✓ Se collegato a un attributo dimensionale, va incluso nella dimension table che contiene l'attributo.
 - ✓ Se collegato direttamente al fatto deve essere incluso nella fact table.
- Ha senso solo se è compatibile con il livello di granularità dell'evento descritto nella fact table, quindi se connesso direttamente alla fact table dovrà essere omesso nelle viste aggregate.

34

Attributi cross-dimensionali


- Dal punto di vista concettuale, un attributo cross-dimensionale b definisce un'associazione molti-a-molti tra due o più attributi dimensionali a_1, \dots, a_m .
- La sua traduzione a livello logico richiede l'inserimento di una nuova tabella che includa b e abbia come chiave gli attributi a_1, \dots, a_m .



35

Gerarchie condivise


- Se una gerarchia si presenta più volte nello stesso fatto (o in due fatti diversi) non conviene introdurre copie ridondanti delle relative dimension table.
- Se le due gerarchie contengono esattamente gli stessi attributi sarà sufficiente importare due volte la chiave della medesima dimension table



36

Gerarchie condivise

- Se le due gerarchie condividono solo una parte degli attributi è necessario decidere se:
 - I. Introdurre ulteriore ridondanza nello schema duplicando le gerarchie e replicando i campi comuni.
 - II. Eseguire uno snowflake sul primo attributo condiviso introducendo una terza tabella comune a entrambe le dimension table.




37

Scelta delle viste

- La scelta delle viste da materializzare è un compito complesso, la soluzione rappresenta un trade-off tra numerosi requisiti in contrasto:
 1. Minimizzazione di funzioni di costo
 2. Vincoli di sistema
 - ✓ **Spazio su disco**
 - ✓ **Tempo a disposizione per l'aggiornamento dei dati**
 3. Vincoli utente
 - ✓ **Tempo massimo di risposta**
 - ✓ **Freschezza dei dati**

38


Scelta delle viste




+ = **viste candidate**,
ossia potenzialmente
utili a ridurre il
costo di esecuzione
del carico di lavoro

39

Scelta delle viste





Minimizzazione
di spazio e tempo





40

Scelta delle viste



41

Scelta delle viste



42



Scelta delle viste

- È utile materializzare una vista quando:
 - ✓ Risolve direttamente una interrogazione frequente
 - ✓ Permette di ridurre il costo di esecuzione di molte interrogazioni

- Non è consigliabile materializzare una vista quando:
 - ✓ Il suo pattern di aggregazione è molto simile a quello di una vista già materializzata
 - ✓ Il suo pattern di aggregazione è molto fine
 - ✓ La materializzazione non riduce di almeno un ordine di grandezza il costo delle interrogazioni